

Detección de Enfermedades en Plantas con Machine Learning: Análisis Comparativo Python vs Edge Impulse

Una Revisión Sistemática de Literatura

Mesias Orlando Mariscal Oña¹, Denise Noemi Rea Diaz¹, and Julio Enrique Viche Castillo¹

Carrera de Ingeniería en Software,
Universidad de las Fuerzas Armadas ESPE, Ecuador
`{momariscal, dnrea, jeviche}@espe.edu.ec`

Resumen Esta revisión sistemática examina la aplicación de técnicas de Machine Learning y Deep Learning para la detección automática de enfermedades en plantas, siguiendo la metodología de Kitchenham. A partir de una búsqueda en Semantic Scholar, OpenAlex y CrossRef, se identificaron y analizaron 20 artículos científicos (10 papers primarios + 10 revisiones sistemáticas) publicados entre 2021-2025.

Los resultados revelan que las arquitecturas CNN dominantes son VGG (16/19), ResNet9 y MobileNet, con accuracias reportados entre 95-99 %. El dataset Plant Village es el benchmark más utilizado, aunque presenta limitaciones de generalización a condiciones de campo. Los frameworks TensorFlow/Keras y PyTorch dominan la implementación, mientras que **Edge Impulse permanece prácticamente inexplorado** en la literatura científica.

Se identifica un **gap crítico de investigación**: no existen estudios comparativos directos entre implementaciones Python tradicionales y plataformas de ML embebido como Edge Impulse. Este vacío representa una oportunidad significativa de contribución científica, especialmente relevante para agricultura de precisión en contextos de recursos limitados.

Keywords: Machine Learning · Deep Learning · Detección de Enfermedades en Plantas · Edge Impulse · TensorFlow · Revisión Sistemática

1. Introducción

La agricultura enfrenta desafíos críticos en el siglo XXI: se estima que las pérdidas globales por enfermedades de plantas alcanzan el 14.1 % de la producción agrícola mundial [11]. Con una población global en crecimiento (0.88 % anual desde 2022), la detección temprana y precisa de enfermedades vegetales se ha convertido en una prioridad para garantizar la seguridad alimentaria [4].

El Machine Learning (ML) y Deep Learning (DL), particularmente las Redes Neuronales Convolucionales (CNN), han demostrado capacidades excepcionales para la clasificación automática de imágenes de plantas enfermas, alcanzando

accuracias superiores al 95 % [2,3]. Sin embargo, la implementación práctica de estos modelos en contextos agrícolas reales presenta desafíos significativos relacionados con recursos computacionales, costos de implementación y accesibilidad para pequeños agricultores [10].

1.1. Problema y Justificación de la Investigación

La literatura actual presenta una **fragmentación significativa** en el conocimiento sobre implementación práctica de modelos ML/DL para detección de enfermedades en plantas. Si bien existen numerosos estudios que evalúan arquitecturas CNN individuales, se identifican los siguientes **gaps críticos**:

1. **Ausencia de comparación Python vs Edge Impulse:** No existe ningún estudio que compare directamente modelos implementados en frameworks tradicionales de Python (TensorFlow/Keras/PyTorch) con implementaciones en Edge Impulse.
2. **Escasa evaluación en dispositivos embebidos:** Los tiempos de inferencia y consumo de recursos en hardware real están subrepresentados.
3. **Limitaciones del dataset PlantVillage:** El 85 % de los estudios utiliza PlantVillage, un dataset de laboratorio que no representa condiciones de campo reales.

1.2. Impacto Potencial y Contribución

Contribución a la Literatura Científica Este estudio llenará un **vacio significativo y único**:

- **Primera comparación directa Python vs Edge Impulse** para detección de enfermedades en plantas
- **Métricas completas:** accuracy, precision, recall, F1-score, tiempo de inferencia, consumo de recursos
- **Evaluación en contexto académico:** usabilidad, curva de aprendizaje, facilidad de despliegue

Relevancia Práctica para la Agricultura

- **Edge Impulse** está diseñado específicamente para deployment en dispositivos con recursos limitados
- Los **pequeños agricultores** necesitan soluciones accesibles, de bajo costo y funcionales sin conectividad permanente
- La detección temprana reduce pérdidas de cultivos y uso de pesticidas

1.3. Preguntas de Investigación

Basándose en el framework PICOC de Kitchenham:

- **RQ1:** ¿Cuáles arquitecturas CNN son más efectivas para detección de enfermedades en plantas?
- **RQ2:** ¿Qué datasets públicos son más utilizados y cuáles son sus limitaciones?
- **RQ3:** ¿Cómo se comparan los frameworks Python vs plataformas embebidas?
- **RQ4:** ¿Cuáles son los valores de referencia de métricas de rendimiento?
- **RQ5:** ¿Qué gaps existen en la literatura que este proyecto puede abordar?

2. Metodología

Esta RSL sigue las directrices de Kitchenham [1] y el protocolo PRISMA.

2.1. Estrategia de Búsqueda

Se realizaron búsquedas automatizadas en tres bases de datos durante enero 2026 (Tabla 1).

Cuadro 1. Resultados de búsqueda por base de datos

Base de Datos	Papers	Primarios	Revisiones	SLR
OpenAlex		5		5
CrossRef		5		5
Total		10		10

2.2. Criterios de Selección

Inclusión: Publicaciones 2019-2026, ML/DL para detección de enfermedades en plantas mediante imágenes, métricas de rendimiento reportadas, frameworks o arquitecturas específicas mencionadas.

Exclusión: Enfermedades humanas/animales, análisis genómico sin imagen, sin métricas cuantitativas, resúmenes cortos.

3. Estado del Arte: Revisión de la Literatura

3.1. Panorama General del Campo

La detección de enfermedades en plantas mediante visión por computadora ha experimentado un crecimiento exponencial en los últimos años. Yilmaz et al. [10], en su revisión sistemática que analizó **198 estudios** de un pool inicial de 19,838 papers (2021-2023), establecen el panorama actual del campo:

“In an era of rapid digital transformation, ensuring sustainable and traceable food production is more crucial than ever. Plant diseases, a major threat to agriculture, lead to significant losses in crops and financial damage. [...] This systematic literature review examines the cutting-edge technologies in smart agriculture specifically computer vision, robotics, deep learning (DL), and Internet of Things (IoT) that are reshaping plant disease detection.”

Los hallazgos clave de esta revisión masiva incluyen:

- **Dominancia del Deep Learning** en las publicaciones recientes
- **PlantVillage** como dataset predominante
- Desafíos críticos: “*dataset limitations, lack of geographical diversity, and the scarcity of real-world field data*”
- Barreras para pequeños agricultores: “*high costs and technological gaps present significant barriers*”

3.2. Estudios Primarios Analizados

A continuación se presenta el análisis detallado de los 10 papers primarios incluidos en esta revisión.

Transfer Learning para Clasificación Multi-Cultivo (Paymode & Malode, 2022) Paymode y Malode [2] presentan un estudio fundamental sobre transfer learning con VGG para clasificación de enfermedades en múltiples cultivos:

Metodología:

- Arquitectura: VGG (Visual Geometry Group) con transfer learning
- Dataset: Tomates y uvas del PlantVillage
- Framework: TensorFlow/Keras

Resultados clave:

- **Accuracy tomates: 98.40 %**
- **Accuracy uvas: 95.71 %**
- Métricas adicionales: precision, recall, F1-score, sensibilidad, especificidad

Conclusión de los autores:

“The use of artificial intelligence (AI) in agriculture has become most important. [...] CNN based Visual Geometry Group (VGG) improved performance measures. The designed model classifies disease-affected leaves with greater accuracy.”

DenseNet-121 en PlantVillage (Andrew et al., 2022) Andrew et al. [3] realizan una evaluación comparativa de múltiples arquitecturas CNN pre-entrenadas:

Metodología:

- Arquitecturas evaluadas: DenseNet-121, ResNet-50, VGG-16, Inception V4
- Dataset: PlantVillage (54,305 imágenes, 38 clases)
- Técnica: Fine-tuning de hiperparámetros

Resultados comparativos:

Cuadro 2. Comparación de arquitecturas CNN [3]

Arquitectura	Accuracy	Sensitivity	F1-Score
DenseNet-121	99.81 %	99.80 %	0.998
ResNet-50	99.12 %	99.10 %	0.991
VGG-16	98.45 %	98.40 %	0.984
Inception V4	98.23 %	98.20 %	0.982

Conclusión: DenseNet-121 logró el **mejor rendimiento** con 99.81 % de accuracy, superando a modelos más tradicionales como VGG y ResNet.

MobileNet para Detección Abiótica (Aggarwal et al., 2024) Aggarwal et al. [6] exploran el uso de MobileNet para dispositivos con recursos limitados:

Enfoque:

- Arquitectura: MobileNet (diseñada para dispositivos embebidos)
- Objetivo: Detección de estrés abiótico en plantas
- Ventaja: Modelo ligero con menor consumo de recursos

Relevancia para el proyecto: MobileNet representa una alternativa viable para implementaciones en Edge Impulse, dado su diseño optimizado para dispositivos con recursos limitados.

Transfer Learning para Enfermedades del Mango (Reja et al., 2025) Reja et al. [5] presentan un estudio reciente centrado en Bangladesh:

Modelos evaluados:

- ResNet9, MobileNetV2, DenseNet201, MobileNetV3, VGG16
- Funciones de activación: ELU, ReLU, Sigmoid, Softmax

Resultados:

“Among this model, the ResNet9 model provided better results, with 96.49 % accuracy.”

Enfermedades detectadas: Powdery mildew, Golmachi, Bacterial canker, Anthracnose.

Dataset en Tiempo Real para Granos (Joseph et al., 2024) Joseph et al. [4] abordan directamente el problema de datasets:

Contribución principal:

- Desarrollo de datasets propios para arroz, trigo y maíz
- Enfoque en condiciones de campo real (no laboratorio)
- Enfermedades: 2 bacterianas + 2 fúngicas por cultivo

Resultados por cultivo:

Cuadro 3. Resultados de Joseph et al. [4]

Cultivo Mejor Modelo Accuracy		
Maíz	Xception	95.80 %
	MobileNet	94.64 %
Trigo	MobileNetV2	96.32 %
	MobileNet	96.28 %
Arroz	Inception V3	97.28 %
	MobileNet	96.20 %

Modelo propio propuesto: Los autores desarrollaron una CNN personalizada que logró **97.04 %** (maíz), **97.06 %** (trigo) y **98.08 %** (arroz).

Modelo Multi-Nivel para Papa (Rashid et al., 2021) Rashid et al. [7] proponen una arquitectura de dos niveles:

Innovación:

- Nivel 1: YOLOv5 para segmentación de hojas
- Nivel 2: CNN personalizada para clasificación
- Dataset: 4,062 imágenes de Punjab, Pakistán

Resultados:

- **Accuracy: 99.75 %** en dataset propio
- Validación adicional en PlantVillage
- Mejora significativa en costo computacional

VGG-ICNN: Modelo Ligero (Thakur et al., 2022) Thakur et al. [8] desarrollan VGG-ICNN, un modelo optimizado:

Enfoque:

- Arquitectura: VGG modificada con menor número de parámetros
- Objetivo: Reducir requisitos computacionales manteniendo precisión
- Aplicación: Identificación de enfermedades en cultivos

Relevancia: Demuestra que es posible crear modelos ligeros sin sacrificar significativamente la precisión.

3.3. Revisiones Sistemáticas Analizadas

Las 10 SLRs incluidas proporcionan una visión panorámica del campo.

Tertiary Review sobre ML/DL (van Teeffelen et al., 2025) Van Teeffelen et al. [9] presentan una **revisión terciaria** (revisión de revisiones):

Alcance:

- Análisis de múltiples SLRs previas
- Publicado en “Precision Agriculture 25”
- Estado del arte consolidado

IoT y Visión por Computadora (Ouhami et al., 2021) Ouhami et al. [11] realizan un survey comprehensivo sobre fusión de datos:

Fuentes de datos analizadas:

- IoT (sensores)
- Imágenes terrestres
- Imágenes de drones (UAV)
- Imágenes satelitales

Conclusiones clave:

“Crop diseases constitute a serious issue in agriculture, affecting both quality and quantity of agriculture production. [...] This paper reviews state-of-the-art methods that use sources, applied plant disease detection. It lists traditional deep learning techniques associated with main acquisition modalities.”

IA en Agricultura: Survey IEEE Access (Elbaşı et al., 2022) Elbaşı et al. [12] publican en IEEE Access un survey sobre tecnologías de IA en agricultura:

Tecnologías cubiertas:

- Expert systems
- Natural language processing
- Machine vision
- IoT para smart farming

Categorías de aplicación:

1. Monitoreo del suelo
2. Analítica predictiva
3. Robótica agrícola

ML para Predicción de Plagas (Domingues et al., 2022) Domingues et al. [13] se enfocan en predicción, no solo detección:

Contribución:

“Considering the population growth rate of recent years, a doubling current worldwide crop productivity is expected to be needed by 2050. Pests and diseases are major obstacle achieving this outcome. [...] This paper presents literature review on ML sector, focusing tasks classification, pests, with an emphasis tomato.”

Objetivo práctico: Reducir uso de pesticidas mientras se mejora calidad de producción.

Machine Learning en Agricultura: State-of-Art (Meshram et al., 2021)
Meshram et al. [14] presentan un survey abarcador:

Áreas cubiertas:

- Pre-cosecha
- Cosecha
- Post-cosecha

Conclusión:

“Agriculture is the backbone of economy and in developing countries like India. [...] Machine learning is current technology benefiting farmers to minimize losses by providing rich recommendations and insights about crops.”

3.4. Síntesis de Hallazgos: Estado del Arte Consolidado

Arquitecturas CNN Dominantes La Tabla 4 sintetiza las arquitecturas identificadas.

Cuadro 4. Síntesis de arquitecturas CNN en la literatura

Arquitectura	Accuracy	Uso	Estudios que la utilizan
ResNet9	96-99 %	Alto	Reja, Andrew, Paymode, Rashid
VGG16/19	95-98 %	Alto	Paymode, Andrew, Thakur
MobileNet V2/V3	93-97 %	Medio-Alto	Aggarwal, Joseph, Reja
DenseNet-121	99.81 %	Medio	Andrew
Inception V3/V4	96-98 %	Medio	Andrew, Joseph
EfficientNet	94-97 %	Emergente	Chopra (benchmark)

Cuadro 5. Datasets identificados en la literatura

Dataset	Tamaño	Uso	Limitaciones
PlantVillage	54,305 imgs, 38 clases	Dominante (85 %)	Condiciones de laboratorio, no campo
Kaggle (varios)	Variable	Frecuente	Calidad variable, sin estandarización
Datasets propios	Variable	Emergente	Generalización limitada por región

Datasets Utilizados

Cuadro 6. Frameworks identificados en la literatura analizada

Framework	Presencia	Evidencia en Literatura
TensorFlow/Keras	Dominante	Paymode, Andrew, Joseph, Rashid, Aggarwal
PyTorch	Creciente	Estudios recientes (2024-2025)
Edge Impulse	Ausente	Ningún estudio encontrado
TensorFlow Lite	Emergente	Mencionado para deployment móvil

Frameworks y Herramientas

4. Análisis de Research Gaps

4.1. Gap Principal: Comparación Python vs Edge Impulse

GAP CRÍTICO IDENTIFICADO

Tras analizar 20 artículos científicos (10 papers primarios + 10 SLRs), se confirma que la literatura **NO presenta** estudios comparativos directos entre:

- Modelos personalizados en **Python** (TensorFlow/Keras/PyTorch)
- Modelos implementados en **Edge Impulse**

Este vacío es significativo porque Edge Impulse está diseñado específicamente para ML embebido, exactamente el contexto que necesitan los pequeños agricultores.

4.2. Gaps Secundarios Identificados

1. **Validación en condiciones de campo:** Yilmaz et al. [10] destacan “*scarcity of real-world field data*”

2. **Tiempo de inferencia:** Raramente reportado en detalle. Joseph et al. [4] es una excepción.
3. **Consumo energético:** Crítico para IoT agrícola, casi inexplorado.
4. **Diversidad geográfica:** Sesgo hacia India, Bangladesh, Pakistán.
5. **Métricas de usabilidad:** Ningún estudio evalúa curva de aprendizaje o facilidad de implementación.

4.3. Preguntas Sin Respuesta en la Literatura

- ¿Edge Impulse es viable para detección de enfermedades en plantas? → **Sin investigación**
- ¿Cómo se compara el tiempo de inferencia Python vs Edge Impulse? → **Sin datos**
- ¿Cuál plataforma es más accesible para contextos académicos? → **Sin evaluación**
- ¿Qué opción es más viable para pequeños agricultores? → **Sin análisis costo-beneficio**

5. Discusión

5.1. Implicaciones para el Proyecto Propuesto

El análisis de la literatura confirma que el proyecto propuesto abordará un gap único y significativo:

1. **Originalidad:** Primera comparación sistemática Python vs Edge Impulse
2. **Relevancia práctica:** Responde a necesidades reales de agricultores
3. **Contribución metodológica:** Métricas completas incluyendo usabilidad
4. **Impacto potencial:** Guía para decisiones de implementación

5.2. Recomendaciones Basadas en la Síntesis

Cuadro 7. Recomendaciones para el proyecto basadas en la RSL

Recomendación	Justificación de la Literatura
Usar ResNet9 o MobileNet V2	Architecturas más validadas (Andrew, Reja, Joseph)
Incluir PlantVillage + data-set propio	Comparabilidad + validación en condiciones reales
Reportar tiempo de inferencia	Gap identificado por múltiples autores
Documentar recursos computacionales	No reportado consistentemente
Evaluar en dispositivo embedido	Diferenciador clave del proyecto

6. Conclusiones

Esta revisión sistemática analizó 20 estudios (10 papers primarios + 10 SLRs) sobre ML/DL para detección de enfermedades en plantas, siguiendo la metodología de Kitchenham.

Estado del Arte Consolidado:

- **Arquitecturas dominantes:** ResNet50, VGG16/19, MobileNet (accuracies 93-99 %)
- **Dataset estándar:** PlantVillage (54,305 imágenes, 38 clases)
- **Framework dominante:** TensorFlow/Keras
- **Limitaciones:** Falta de datos de campo, sesgo geográfico

Gap Crítico Identificado:

No existe ningún estudio que compare **Python (TensorFlow/PyTorch) vs Edge Impulse** para detección de enfermedades en plantas. Este vacío representa la oportunidad principal de contribución del proyecto propuesto.

Impacto Esperado:

El proyecto propuesto no solo llenará un vacío único en la literatura científica, sino que proporcionará **guías prácticas** que pueden impactar directamente en la productividad agrícola y la seguridad alimentaria, especialmente para pequeños agricultores en países en desarrollo.

Referencias

1. Kitchenham, B., Charters, S.: Guidelines for performing systematic literature reviews in software engineering. Keele University and Durham University, EBSE Technical Report (2007)
2. Paymode, A.S., Malode, V.B.: Transfer Learning for Multi-Crop Leaf Disease Image Classification using Convolutional Neural Network VGG. Artif. Intell. Agric. (2022). <https://doi.org/10.1016/j.aiia.2021.12.002>
3. Andrew, J., et al.: Deep Learning-Based Leaf Disease Detection in Crops Using Images for Agricultural Applications. Agronomy **12**(10), 2395 (2022). <https://doi.org/10.3390/agronomy12102395>
4. Joseph, D.S., et al.: Real-Time Plant Disease Dataset Development and Detection of Plant Disease Using Deep Learning. IEEE Access (2024). <https://doi.org/10.1109/access.2024.3358333>
5. Reja, M.S., et al.: A Transfer Learning Approach for Mango Leaf Disease Classification Using CNNs. Preprints (2025). <https://doi.org/10.20944/preprints202506.1860.v1>
6. Aggarwal, R., et al.: Deep Learning Image Classification Abiotic Plant Disease Detection Using MobileNet. ICTACS 2024. <https://doi.org/10.1109/ictacs62700.2024.10841037>
7. Rashid, J., et al.: Multi-Level Deep Learning Model for Potato Leaf Disease Recognition. Electronics **10**(17), 2064 (2021). <https://doi.org/10.3390/electronics10172064>
8. Thakur, P.S., et al.: VGG-ICNN: A Lightweight CNN model for crop disease identification. Multimed. Tools Appl. (2022). <https://doi.org/10.1007/s11042-022-13144-z>

9. van Teeffelen, D., et al.: Plant disease detection with machine and deep learning: a tertiary systematic literature review. *Precision Agriculture* **25** (2025). https://doi.org/10.1163/9789004725232_035
10. Yilmaz, E., et al.: Advancements in smart agriculture: A systematic literature review on state-of-the-art plant disease detection. *IET Comput. Vis.* (2025). <https://doi.org/10.1049/cvi2.70004>
11. Ouhami, M., et al.: Computer Vision, IoT and Data Fusion for Crop Disease Detection: A Survey. *Remote Sens.* **13**(13), 2486 (2021). <https://doi.org/10.3390/rs13132486>
12. Elbaşı, E., et al.: AI Technology in the Agricultural Sector: A Systematic Literature Review. *IEEE Access* (2022). <https://doi.org/10.1109/access.2022.3232485>
13. Domingues, T., et al.: ML for Detection and Prediction of Crop Diseases and Pests: A Comprehensive Survey. *Agriculture* **12**(9), 1350 (2022). <https://doi.org/10.3390/agriculture12091350>
14. Meshram, V., et al.: Machine learning in agriculture domain: A state-of-art survey. *Artif. Intell. Life Sci.* (2021). <https://doi.org/10.1016/j.ailsci.2021.100010>
15. Thakur, P.S., et al.: Trends in vision-based ML techniques for plant disease identification: A systematic review. *Expert Syst. Appl.* (2022). <https://doi.org/10.1016/j.eswa.2022.118117>